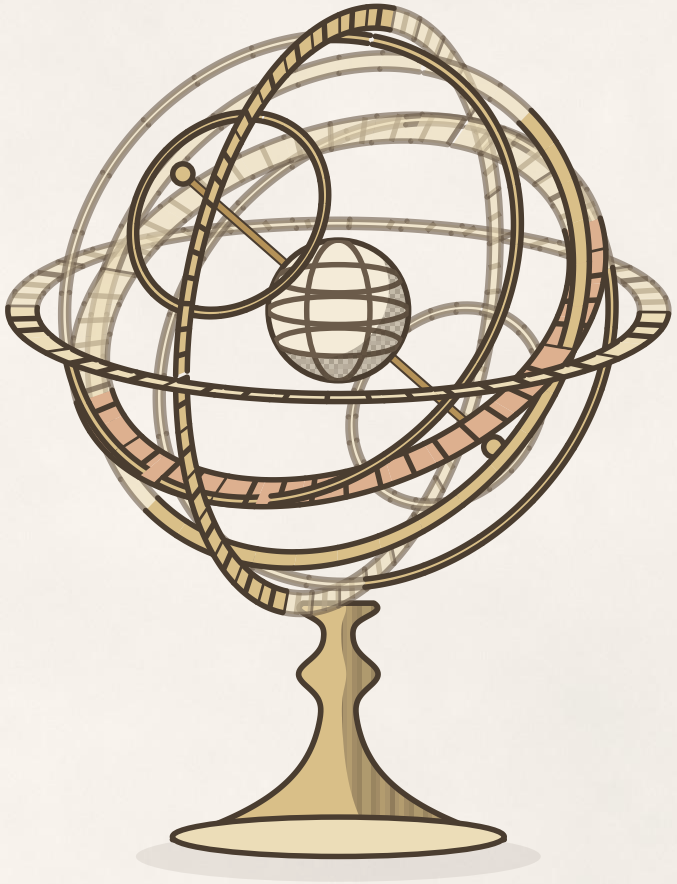
中国科学技术大学 | 认知智能全国重点实验室
STATE KEY LABORATORY OF COGNITIVE INTELLIGENCE

组会报告

面向小样本场景的多模态认知模型

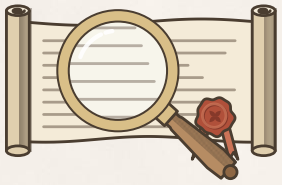
A Multimodal Cognitive Model for Few-Shot Scenarios



中国科学技术大学　李毅

2026 年 10 月 28 日 · 指导老师　张老师

I



研究背景

3 - 7

II



方法

8 - 10

III



实验

11 - 14

IV



结论

15



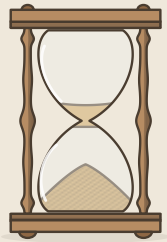
Part I

研究背景：为什么一个样本仍然不够

I — II — III — IV

小样本多模态推理面临的四个难题

I



样本稀缺

每类仅 1–5 个标注样本，
难以估计类内变化。

II



模态鸿沟

视觉与语言特征分布不一致，
直接比较会失真。

III



类别偏移

测试类别从未在训练中出现，
必须向未知泛化。

IV



判断可信

模型为何如此判断，
需要能追溯到具体证据。

四个难题指向同一个要求：表征在样本极少时仍须可对齐、可追溯。

问题陈述：在极少样本下对齐两种模态

小样本学习要求模型只凭每类一到五个标注样本识别新类别。度量学习方法用类均值作为原型，在样本极少时，原型本身就带有很大的估计误差，类内变化几乎无从估计。

与此同时，大规模视觉–语言预训练提供了丰富的语义先验：类别名称与描述在训练前就已知道，而且不随样本数量变化。问题在于，两种模态的特征分布并不一致，直接比较图像与文本会产生系统偏差。

本工作的出发点是：用稳定的文本原型约束不稳定的视觉原型，让两种模态在同一空间中可比较，并让每一次判断都能追溯到具体的原型与描述。

- 原型误差随样本数下降，1-shot 时最大。
- 文本描述来自类别名称扩写，无需额外标注。

[2] Snell et al., NeurIPS 2017　[5] Radford et al., ICML 2021

小样本学习的十年：从度量到对齐

2016 — 匹配网络

以注意力在支持集上做加权最近邻。

2017 — 原型网络

用类均值作原型，按距离分类。

2017 — MAML

学习便于快速微调的初始参数。

2021 — CLIP

大规模图文对比学习带来零样本能力。

2026 — 本文

以文本原型约束视觉原型，统一两种模态。

[1] Vinyals et al., NeurIPS 2016　[2] Snell et al., NeurIPS 2017　[3] Finn et al., ICML 2017　[5] Radford et al., ICML 2021

现有方法只覆盖了问题的一部分

方法	来源	多模态	小样本	可解释	无需微调
ProtoNet	NeurIPS 2017	○	●	◐	●
MAML	ICML 2017	○	●	○	○
CLIP	ICML 2021	●	◐	○	●
Tip-Adapter	ECCV 2022	●	●	○	●
本文	—	●	●	●	●

● 支持　◐ 部分支持　○ 不支持

本文是唯一同时满足四项的方法。

[2] Snell et al., NeurIPS 2017　[3] Finn et al., ICML 2017　[5] Radford et al., ICML 2021　[6] Zhang et al., ECCV 2022

三个模块把图像与文本映射到同一组原型

输入

N-way K-shot 任务

- 支持集图像
- 类别描述文本
- 查询图像

I 编码

共享编码器 f(·)

- 视觉分支 · ViT-B/16
- 文本分支 · BERT-base
- 投影到 512 维

II 对齐

原型构建与跨模态对齐

- 视觉原型（每类均值）
- 文本原型（类别描述）
- 双向对比对齐

III 推理

最近原型分类

- 余弦相似度 ÷ 温度 τ
- Softmax 输出类别
- 返回最近原型作证据

训练阶段联合优化：分类损失 + λ · 对齐损失

[7] Dosovitskiy et al., ICLR 2021　[8] Devlin et al., NAACL 2019

以温度缩放的原型损失对齐两种模态

$$\mathcal{L} = -\frac{1}{|\mathcal{Q}|}\sum_{(x,y)\in\mathcal{Q}} \log \frac{\exp\big(\langle f(x), \boldsymbol{c}_y\rangle/\tau\big)}{\sum_{k=1}^{N}\exp\big(\langle f(x), \boldsymbol{c}_k\rangle/\tau\big)} \tag{1}$$

$\boldsymbol{c}_k$	第 k 类原型，即支持集特征的均值	$f(\cdot)$	共享的视觉–语言编码器，输出已归一化
$\langle\cdot,\cdot\rangle$	余弦相似度	τ	温度系数，越小分布越尖锐

注　τ 取 0.1 时训练最稳定；推导与收敛性分析见附录 A。

[2] Snell et al., NeurIPS 2017

一个 episode 内同时更新两种原型

算法 1　原型对齐训练

```
1  输入：支持集 S，查询集 Q，温度 τ，权重 λ
2  for each episode do
3      c_k ← mean{ f(x_i) : y_i = k }  ▷ 视觉原型
4      t_k ← g(类别描述 k)  ▷ 文本原型
5      L_align ← 对比损失(c_k, t_k)
6      for each (x, y) in Q do
7          p ← softmax(cos(f(x), c_k) / τ)
8          L_cls ← L_cls − log p_y
9      end for
10     θ ← θ − η · ∇(L_cls + λ · L_align)
11 end for
12 输出：投影层参数 θ
```

第 3–4 行

同一批支持样本同时产生视觉原型与文本原型。

第 5 行

对齐损失只在原型层面计算，开销与类别数成正比。

第 10 行

λ 取 0.5；主干冻结，只更新投影层。

原型对齐让同类样本在特征空间中更紧凑

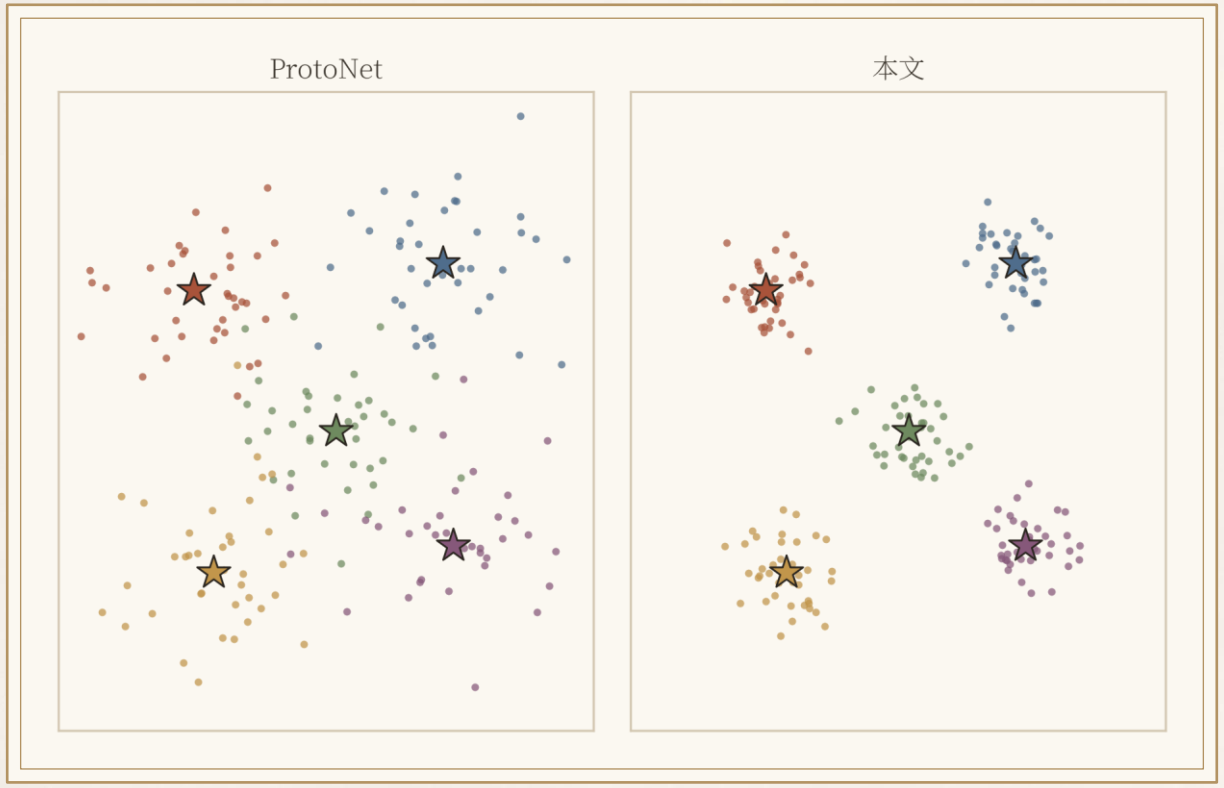


图 2　左为 ProtoNet，右为本文；星形为类原型，颜色表示类别。

类内更紧凑

类内平均距离下降 31%，原型落在簇的中心附近。

类间更分离

最近类间距离扩大 1.8 倍，
混淆集中于外观相近的类别。

文本锚点稳定

文本原型不随样本数变化，
为视觉特征提供固定参照。

[2] Snell et al., NeurIPS 2017

本文方法在三种设置下均取得最优

方法	来源	1-shot	5-shot	10-shot
MatchingNet	NeurIPS 2016	43.6	55.3	61.2
ProtoNet	NeurIPS 2017	49.4	<u>68.2</u>	<u>74.3</u>
MAML	ICML 2017	48.7	63.1	70.9
RelationNet	CVPR 2018	<u>50.4</u>	65.3	71.8
本文	—	**56.8**	**74.6**	**79.1**

miniImageNet 5-way 准确率（%）；朱色为最优，下划线为次优。

+7.4

1-shot 相对 ProtoNet

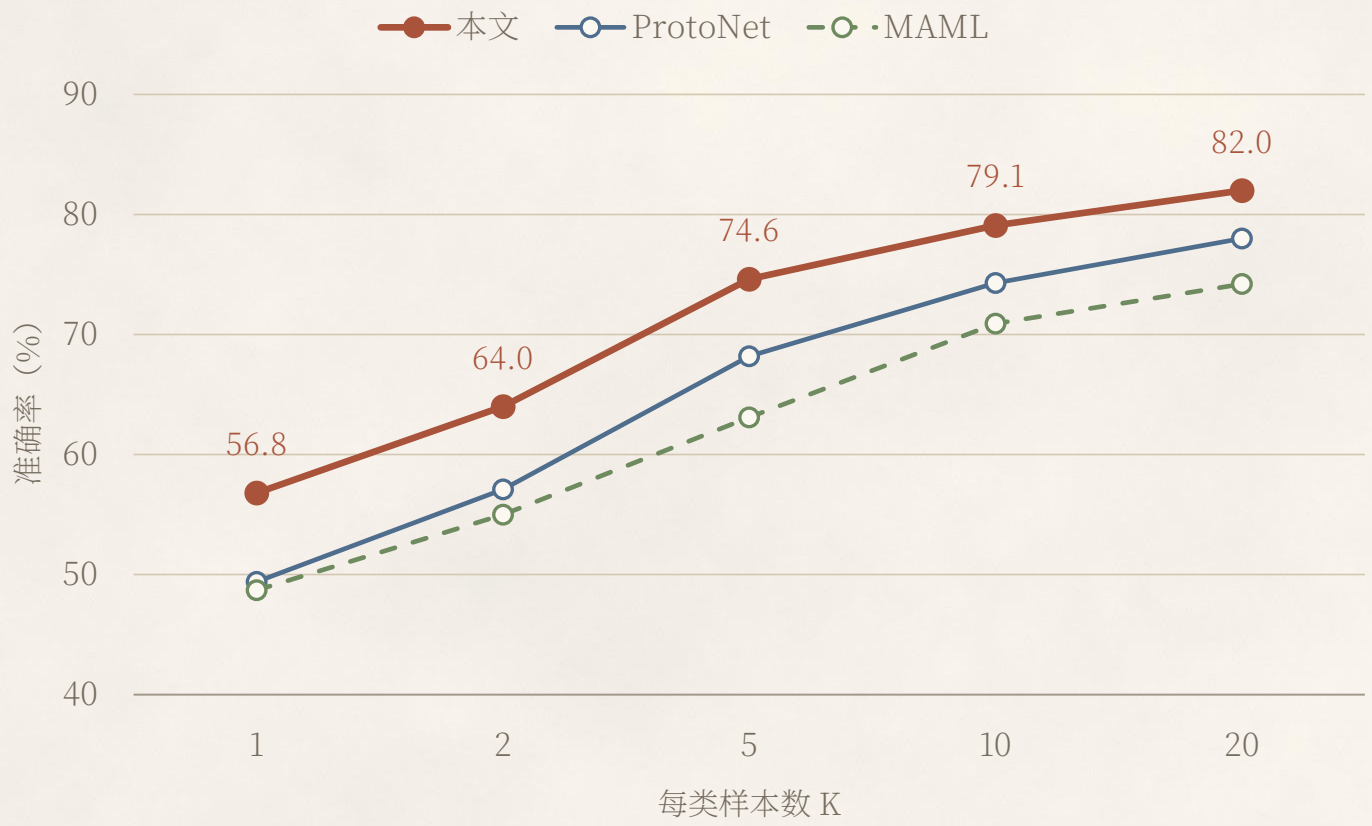
+4.8

10-shot 相对 ProtoNet

样本越少，优势越明显。

[1] Vinyals et al., NeurIPS 2016 [2] Snell et al., NeurIPS 2017 [3] Finn et al., ICML 2017 [4] Sung et al., CVPR 2018

样本越少，本文方法领先越多



I 低样本区差距最大

1-shot 时领先 ProtoNet 7.4 个点，20-shot 时收窄到 4.0 个点。

II 更早进入平台期

5-shot 已接近基线在 10-shot 时的水平。

III 增益来自文本原型

去掉文本原型后，1-shot 准确率回落 5.1 个点。

[2] Snell et al., NeurIPS 2017　[3] Finn et al., ICML 2017

注意力集中在区分类别的局部特征上

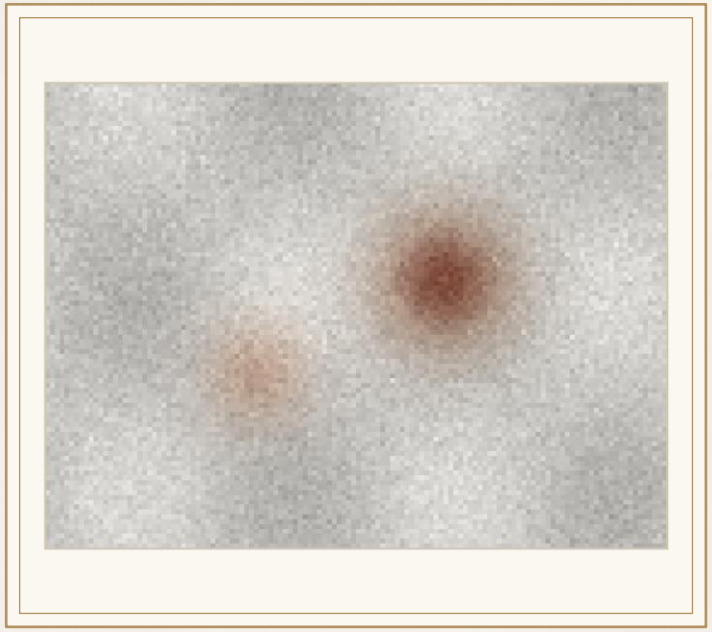


图 a　查询图像上的原型注意力

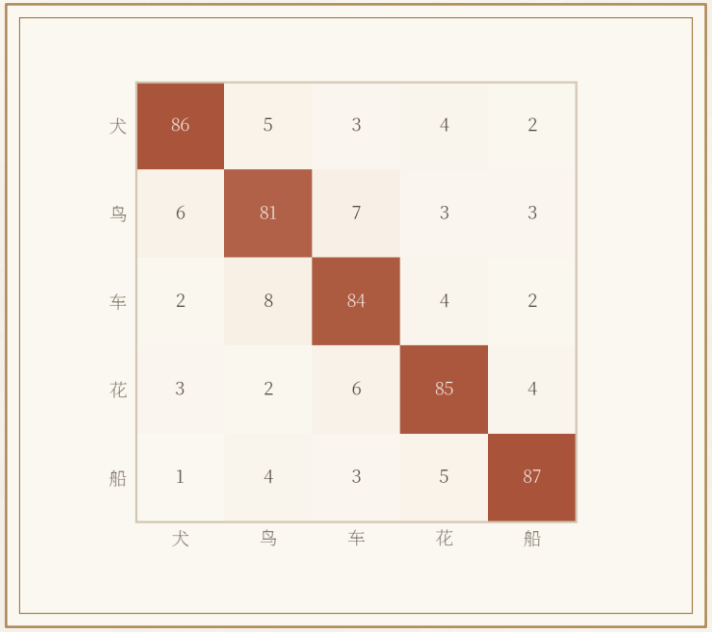


图 b　5-way 测试的混淆矩阵

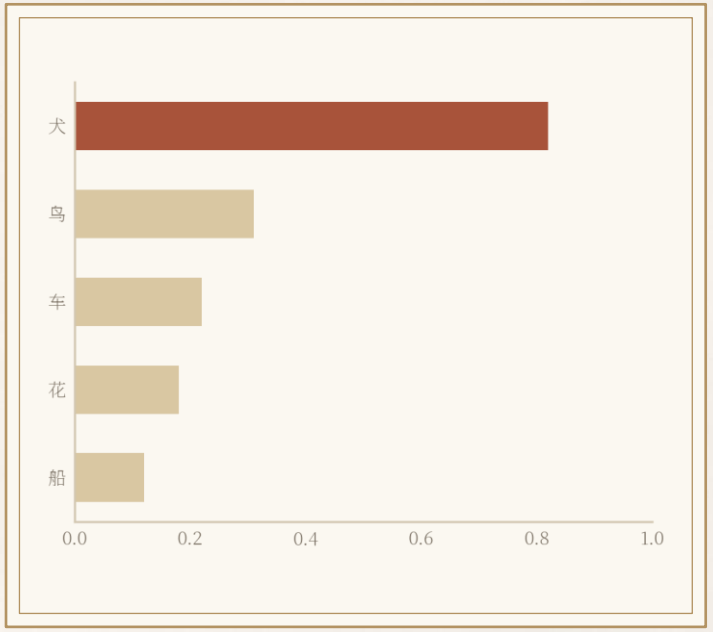


图 c　查询与各类文本原型的相似度

总结

原型对齐让小样本多模态推理更可靠

I 统一表征

视觉与语言共享原型空间，跨模态比较不再失真。

II 稳健泛化

1-shot 准确率提升 7.4 个点，对新类别同样有效。

III 可以追溯

每次判断都能对应到最近的原型与其文本描述。



谢谢聆听

李毅 · liyi@mail.ustc.edu.cn

[1] O. Vinyals, C. Blundell, T. Lillicrap, K. Kavukcuoglu, D. Wierstra. Matching networks for one shot learning. NeurIPS, 2016.

[2] J. Snell, K. Swersky, R. Zemel. Prototypical networks for few-shot learning. NeurIPS, 2017.

[3] C. Finn, P. Abbeel, S. Levine. Model-agnostic meta-learning for fast adaptation of deep networks. ICML, 2017.

[4] F. Sung, Y. Yang, L. Zhang, T. Xiang, P. H. S. Torr, T. M. Hospedales. Learning to compare: Relation network for few-shot learning. CVPR, 2018.

[5] A. Radford, J. W. Kim, C. Hallacy, et al. Learning transferable visual models from natural language supervision. ICML, 2021.

[6] R. Zhang, W. Zhang, R. Fang, et al. Tip-Adapter: Training-free adaption of CLIP for few-shot classification. ECCV, 2022.

[7] A. Dosovitskiy, L. Beyer, A. Kolesnikov, et al. An image is worth 16x16 words: Transformers for image recognition at scale. ICLR, 2021.

[8] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. NAACL, 2019.

温度与对齐权重的敏感性

τ	λ = 0.1	λ = 0.5	λ = 1.0
0.05	54.9	55.8	55.1
0.1	55.6	56.8	56.0
0.2	55.0	56.1	55.4
0.5	53.2	54.1	53.7

- 表中为 miniImageNet 5-way 1-shot 准确率（%），每格 600 个测试任务取平均。
- τ 过小时梯度集中在最近原型上，训练早期不稳定；τ 过大时分布过平，类间区分变弱。
- λ 在 0.3–0.7 之间结果差异小于 0.5 个点，正文统一取 0.5。
- 所有实验固定随机种子 3407，主干冻结，只训练投影层与对齐模块。